

تمرین ۱. مقایسه **Linear Regression**، **Elastic Net** و تأثیر کاهش ابعاد با **PCA**

مقدمه

دیتاست **California Housing** شامل ۲۰,۶۴۰ نمونه با ۸ ویژگی عددی است که از سرشماری ۱۹۹۰ ایالات متحده گرفته شده. هدف پیش‌بینی قیمت متوسط مسکن (به صد هزار دلار) در مناطق مختلف کالیفرنیاست.

در این تمرین جامع، سه رویکرد مختلف را مقایسه می‌کنیم:

۱. **Linear Regression** (مدل پایه)
۲. **Elastic Net Regression** (با regularization)
۳. **Linear Regression + PCA** (کاهش ابعاد)

ویژگی‌های دیتاست

دیتاست شامل ویژگی‌های زیر است:

- **MedInc**: متوسط درآمد در منطقه
- **HouseAge**: متوسط سن خانه‌ها
- **AveRooms**: تعداد متوسط اتاق‌ها در هر خانوار
- **AveBedrms**: تعداد متوسط اتاق خواب‌ها
- **Population**: جمعیت منطقه
- **AveOccup**: متوسط تعداد افراد در هر خانوار
- **Latitude**: عرض جغرافیایی
- **Longitude**: طول جغرافیایی

هدف: **MedHouseVal** (قیمت متوسط خانه به صد هزار دلار)

بخش ۱: بارگذاری و آشنایی با داده

۱-۱. با استفاده از کد زیر داده را بارگذاری کنید:

```
from sklearn.datasets import fetch_california_housing
```

بخش ۲: آماده‌سازی داده

۲-۱. داده را به ویژگی‌ها (X) و متغیر هدف (y) تقسیم کنید.

۲-۲. با نسبت ۸۰-۲۰ داده را به `train` و `test` تقسیم کنید. از `random_state=42` استفاده کنید.

۲-۳. با استفاده از `StandardScaler`، داده `train` را `fit` کرده و هر دو مجموعه `train` و `test` را `transform` کنید.

بخش ۳: مدل Linear Regression پایه

۳-۱. یک مدل `Linear Regression` بسازید و روی داده `train` آموزش دهید.

۳-۲. برای این مدل موارد زیر را محاسبه و گزارش کنید:

- `R2_score` روی `train`
- `R2_score` روی `test`
- اختلاف بین اعداد بالا را بررسی کنید (شاخص `overfitting`)

۳-۳. ضرایب (`coefficients`) مدل را به همراه نام ویژگی‌ها نمایش دهید و به ترتیب نزولی مرتب کنید. کدام ویژگی بیشترین تأثیر مثبت (بزرگترین ضریب مثبت) روی قیمت مسکن دارد؟

بخش ۴: مدل Elastic Net اولیه

۴-۱. یک مدل ElasticNet با پارامترهای $\alpha=0.1$ و $l1_ratio=0.5$ بسازید و آموزش دهید. (برای فهم هاپر پارامترهای داده شده به بخش ۶ مراجعه کنید)

۴-۲. همان معیارهای بخش ۳ را برای این مدل محاسبه کنید:

- R^2_score روی train
- R^2_score روی test
- اختلاف بین اعداد بالا را بررسی کنید (شاخص overfitting)

۴-۳. ضرایب Elastic Net را با Linear Regression مقایسه کنید. یک جدول بسازید که شامل نام ویژگی، ضریب Linear، ضریب Elastic Net، و اختلاف آن‌ها باشد. آیا Elastic Net ضرایب را کوچک‌تر (shrink) کرده است؟

۵-۳. تحلیل کنید:

- کدام مدل overfitting کمتری دارد؟ چگونه تشخیص دادید؟
- Elastic Net چگونه ضرایب را تغییر داده است؟ (مفهوم shrinkage)
- کدام مدل برای generalization (عملکرد روی داده جدید) بهتر است؟

بخش ۶: توضیحات و سوالات تحلیلی

۶-۱- توضیح هاپر پارامترها (این بخش برای مطالعه است که درک بهتری پیدا کنید)

Alpha یک هاپر پارامتر است که مشخص می‌کند چقدر پنالتی (جریمه) به ضرایب بزرگ اعمال شود:

- **Alpha کوچک (مثلاً ۰,۰۱):** پنالتی کم $\rightarrow$ مدل آزادتر است $\rightarrow$ ضرایب بزرگ‌تر $\rightarrow$ خطر overfitting

- **Alpha** بزرگ (مثل ۱۰): پنالتی زیاد → مدل محدودتر است → ضرایب کوچک‌تر → خطر underfitting
- **Alpha** بهینه: تعادل بین پیچیدگی و generalization، معمولاً با **Cross-Validation** پیدا می‌شود در این سوال هدف پیدا کردن بهترین مقدار alpha نبوده صرفاً هدف آشنایی شما با این هاپیر پارامتر است
- **پنالتی یعنی:** مدل برای هر ضریب بزرگ، یک جریمه به تابع هزینه اضافه می‌کند، پس مجبور می‌شود ضرایب کوچک‌تری انتخاب کند تا overfitting نشود.
- **l1_ratio** مشخص می‌کند که چه درصدی از پنالتی **L1** و چه درصدی **L2** باشد.

وقتی:

$l1_ratio = 0.5$

یعنی:

- ۵۰٪ **L1 (Lasso)**
- ۵۰٪ **L2 (Ridge)**

۲-۶. سوال تحلیلی:

• Regularization چیست؟

تعریف Regularization در مدل‌های یادگیری ماشین چیست و چرا بدون آن، مدل‌ها مستعد **overfitting** می‌شوند؟

• انواع Regularization

به طور مشخص، دو روش زیر را توضیح دهید:

- **L1 Regularization (Lasso)**
- **L2 Regularization (Ridge)**

و تفاوت‌های آن‌ها را از نظر:

- نحوه جریمه کردن ضرایب
- تأثیر بر مقدار ضرایب
- حذف یا باقی ماندن ویژگی‌ها (feature selection)

• Elastic Net Regularization

توضیح دهید Elastic Net چگونه ترکیبی از L1 و L2 است و چرا در برخی مسائل (به ویژه زمانی که ویژگی‌ها با یکدیگر هم بستگی دارند) نسبت به Lasso یا Ridge خالص عملکرد بهتری دارد.

بخش ۷: کاهش ابعاد با PCA

در این بخش می‌خواهیم ببینیم اگر تعداد ویژگی‌ها را با PCA کاهش دهیم، چه تأثیری روی عملکرد مدل دارد.

۷-۱. کاهش ابعاد با PCA

یک مدل PCA با ۵ مؤلفه اصلی بسازید و روی `X_train_scaled` آموزش دهید. سپس هر دو مجموعه `train` و `test` را transform کنید.

۷-۲. آموزش Linear Regression روی داده کاهش یافته

یک مدل LinearRegression روی داده تبدیل شده PCA آموزش دهید و معیارهای زیر را محاسبه کنید:

- $Train R^2$ و $Test R^2$
- اختلاف بین اعداد بالا را بررسی کنید (شاخص overfitting)

۸. بخش تحلیلی: مقایسه سه رویکرد

در این بخش باید سه مدل را با هم مقایسه کنید:

1. **Linear Regression** (بدون regularization)
2. **Elastic Net** (بهینه regularization با)
3. **Linear Regression + PCA** (با داده کاهش یافته)

تحلیل کنید:

- کدام مدل بهترین $Test R^2$ را دارد؟
- آیا کاهش ابعاد با PCA باعث بهبود generalization شد؟
- چرا Elastic Net نسبت به Linear Regression ساده بهتر/بدتر عمل کرد؟

تمرین ۲. بررسی Random Forest برای پیش‌بینی بیماری قلبی (Heart Disease)

یک مرکز پزشکی می‌خواهد با استفاده از الگوریتم **Random Forest**، احتمال ابتلا به بیماری قلبی را در بیماران پیش‌بینی کند. داده‌های بیماران کلینیک کلیولند در اختیار شماست.

لینک دیتا :

<https://drive.google.com/file/d/1quJH3KqmUd7ZBVaU4f4GtgoX0NWtAda8/view?usp=sharing>

ویژگی‌های دیتاست:

ویژگی‌های ورودی:

- **age**: سن بیمار
- **sex**: جنسیت (۱ = مرد، ۰ = زن)
- **cp**: نوع درد قفسه سینه (۰-۳)
- **trestbps**: فشار خون استراحت (mm Hg)
- **chol**: کلسترول سرم (mg/dl)
- **fbs**: قند خون ناشتا (۱ = بله، ۰ = خیر)
- **restecg**: نتایج الکتروکاردیوگرافی استراحت (۰-۲)
- **thalach**: حداکثر ضربان قلب
- **exang**: آنژین ناشی از ورزش (۱ = بله، ۰ = خیر)
- **oldpeak**: افسردگی ST ناشی از ورزش
- **slope**: شیب بخش ST در اوج ورزش
- **ca**: تعداد رگ‌های اصلی
- **thal**: تالاسمی

متغیر هدف:

- **condition**: وجود بیماری قلبی (۰ = سالم، ۱ = بیمار)

بخش ۱. پیش‌نیاز: مطالعه Information Gain و Gini Impurity

قبل از شروع، الزامی است با مفاهیم زیر آشنا شوید:

۱. **Gini Impurity** چیست و چگونه محاسبه می‌شود؟
۲. **Information Gain** چیست و چگونه محاسبه می‌شود؟

بخش ۲: بارگذاری و بررسی داده

- ۱-۲. داده را به X (ویژگی‌ها) و y (هدف) تقسیم کنید. سپس با نسبت ۷۰-۳۰ به `train` و `test` تقسیم کنید (`random_state=42`). تعداد نمونه‌های `train` و `test` را گزارش دهید.

بخش ۳: ساخت و آموزش Random Forest

- ۳-۱. یک مدل **RandomForestClassifier** با پارامترهای زیر بسازید و آموزش دهید:

- `n_estimators=100`
- `criterion='gini'`
- `max_depth=4`
- `random_state=42`

- ۳-۲. **Accuracy** مدل **Random Forest** را روی مجموعه `train` و `test` محاسبه کنید. آیا مدل دچار **overfitting** است؟ (اختلاف بین **Train Accuracy** و **Test Accuracy** را تحلیل کنید)

- ۳-۳. **Feature Importance** را محاسبه کنید و نمودار نواری رسم کنید. کدام ویژگی‌ها مهم‌ترین نقش را در تشخیص بیماری قلبی دارند؟

- ۳-۴. **تحلیل کنید:** چرا **Random Forest** معمولاً **overfitting** کمتری نسبت به یک **Decision Tree** دارد؟

بخش ۴: ارزیابی پیشرفته - Confusion Matrix و تحلیل خطاها

قبل از این بخش، الزامی است مفاهیم **Precision, Recall, F1-Score** را مطالعه کنید:

- <https://www.geeksforgeeks.org/machine-learning/f1-score-in-machine-learning/>

۴-۱. رسم و تحلیل Confusion Matrix

الف) برای مدل Random Forest (با Gini)، **Confusion Matrix** رسم کنید و از آن موارد زیر را استخراج کنید:

- **TP (True Positive)**: بیماران صحیح تشخیص داده شده
- **TN (True Negative)**: سالم‌های صحیح تشخیص داده شده
- **FP (False Positive)**: سالم‌هایی که اشتباه بیمار تشخیص داده شدند
- **FN (False Negative)**: بیمارانی که اشتباه سالم تشخیص داده شدند

ب) تعداد هر کدام از موارد بالا را از Confusion Matrix در هنگام ارایه خود استخراج و گزارش کنید.

ج) با توجه به تحلیل بالا، در سیستم تشخیص پزشکی قلب، از دست دادن یک بیمار (FN) خطرناک‌تر است یا تشخیص اشتباه سالم به عنوان بیمار (FP)؟